Analisis Konseptual

1. Proses Batch Norm bisa menyebabkan instabilitaas pelatihan apabial distribusi dari data setiap batch sangat berbeda. Karena batch normalization menghitung mean dan variance di masing2 batch bisa saja ada sample yang sama yg memiliki nilai berbeda karena perbedaan data disekitarnya.

2.

A. Penambahan kedalaman lapisan pada plain CNN bisa mengalami penurunan akurasi karena dalam proses model yang dalam, bisa saja model melupakan informasi yang sudah ada. Dan juga akurasi dari model yang dalam bisa saja lebih buruk dari yang dangkal karena proses backprop akan melewati lebih banyak layer yang menyebabkan perubahan gradien di lapisan awal tidak stabil.

B. Dengan menggunakan skip connection input akan langsung dikirim ke layer sebelumnya tanpa melewati proses diferensiasi. y = F(x) + x, di mana F(x) adalah data yang melewati diferensiasi dan ditambahkan dengan data yang tidak melewati proses diferensiasi (x)

C. Dengan mengirimklan data langsung ke layer sebelumnya, ini akan mencegah gradien (y) untuk mengalami vanishing gradient karena data sebelumnya akan ditambahkan dan tidak hanya hasil diferensiasi

3.

Perbandingan	Feature Extract	Fine Tune
Jumlah parameter yang diperbarui	Lebih sedikit karena yang diubah hanya classifier head	Lebih banyak tergantung dari konfigurasinya
Kebutuhan volume data latih.	Membutuhkan lebih sedikit data karena ada fitur pretrained bawaan	Membutuhkan data lebih banyak agar optimasi fitur sesuai (tidak overfit)
Beban komputasi dan memori per epoch.	Lebih ringan karena tidak perlu mengubah backbone	Lebih berat karena perlu mengoptimasi weight di backbone
Risiko rusaknya fitur representasi bawaan (destructive gradient updates)	Rendah karena fitur bawaan atau backbone tidak dirubah sama sekali	Lebih tinggi karena ada proses perubahan parameter pre trained model
Kapan dipilih ?	Dataset kecil, sumber daya terbatas	Seluruh resource terpenuhi (data, gpu,dll), fitur pre trained model belum terlalu cocok

4.

A. Augmentasi data dilakukan kepada train set untuk melatih model agar model memiliki regularisasi yang baik. Sedangkan pada val/test set ini tidak diperlukan karena val/test bertujuan untuk mengukur performa model pada situasi asli. Tapi approach ini juga tidak dilarang sepenuhnya.

B. Salah satu teknik augmentasi yang tidak sesuai dengan klasifikasi hewan adalah teknik cropping. Karena teknik cropping yang agresif dapat menghilangkan fitur penting yang merepresentasikan bentuk model hewan tersebut.

5.

A. Proses hilangnya representasi bawaan adalah ketika hasil dari proses fine tune merubah bobot secara drastic sehingga weight dari model yang awalnya bersifat general bisa menjadi overfit kepada data fine tune dan melupakan pola yg dipelajari sebelumnya

B.

Differential Learning Rate

- Learning rate pada layer2 awal dibuat sangat kecil, pada layer akhir dibuat lebih besar
- Secara teoritis layer2 awal dibuat kecil untuk membuat model tidak melupakan informasi dari pretrain sedangkan pada layer2 akhir dibuat besar agar model bisa mengenal class kita yang baru (parameter baru diinisialiasi)

Gradual Unfreezing

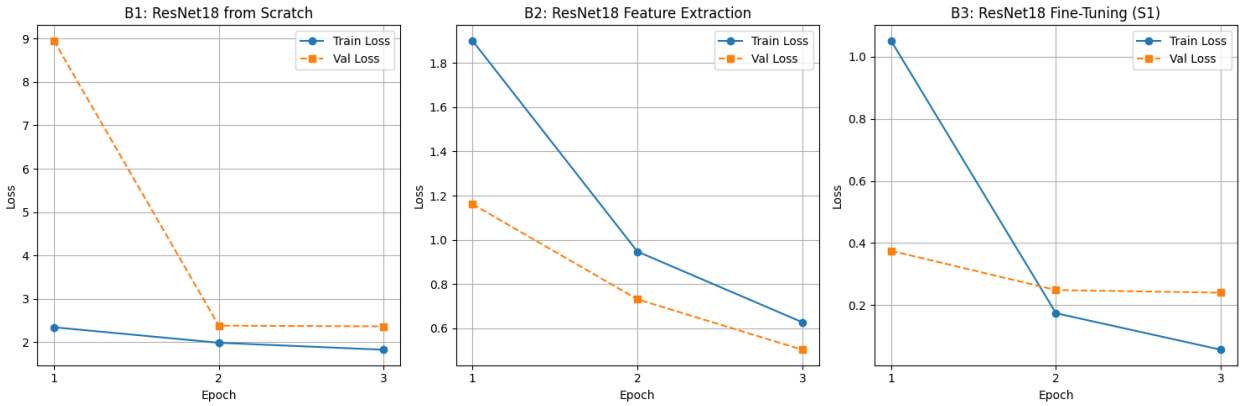
- Tahap 1 bekukan backbone dan latih classifier head
- Tahap 2 buka backbone terakhir -> evaluasi
- Buka layer lagi jika diperlukan
- Efektif karena pendekatan ini menjaga representasi pretrained model dan kitab isa dengan manual menghentikaannya apabila hasil sudah cukup

Laporan

C1. Tabel Konsolidasi dan Visualisasi Pembelajaran

Model	Trainable Params	Learning Rate	Best Epoch	Total Waktu	Val accuracy (%)	Val Macro F1
B1	11,689,512	1e-3	3	20.32s	22.50	0.2048
B2	5,120	1e-3	3	12.83s	88.50	0.8826
B3 S1	8,393,856	1e-4, 1e-3	2	12.73s	93.50	0.9315
B3 S2	8,393,856	1e-4, 1e-3	3	17.73s	89.50	0.8993
B5	657,546	1e-4, 1e-3	3	13.21s	88.00	0.8834

Perbandingan Grafik :



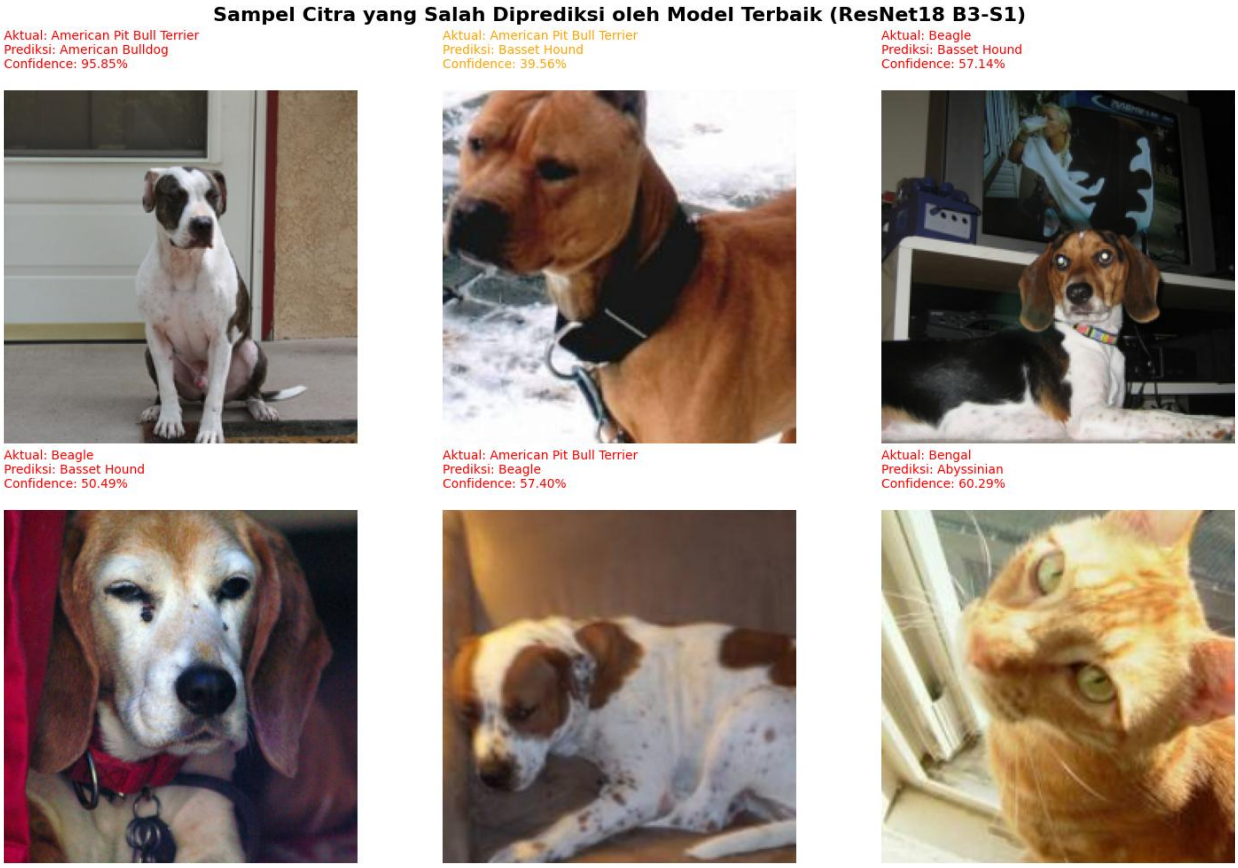
C2. Pembahasan Analisis Komparatif

A. Terjadi disparaitas performa yang tajam antara B1 dengan B2 dan B3 karena model B1 tidak memiliki pengetahuan sama sekali jika dibandingkan dengan pretrained (sudah pernah dilatih sebelumnya)

B. Dalam hal ini waktu yang diperlukan untuk fine tune dan feature extract tidak berbeda jauh karena kapasitas dari GPU yg digunakan. Tetapi jika kita melihat dari jumlah trainable param kita bisa melihat perbedaan yang signifikan. Untuk kasus ini Fine tune lebih baik karena menghasilkan akurasi yg lebih baik walaupun cenderung overfit

C. B4 lumayan berpengaruh apabila kita melihat dari training accuracy dan validation accuracy. Walaupun validation accuracy lebih rendah pada B4. B4 mengurangi training accuracy yang cenderung overfit pada B# (99%) menjadi 96%

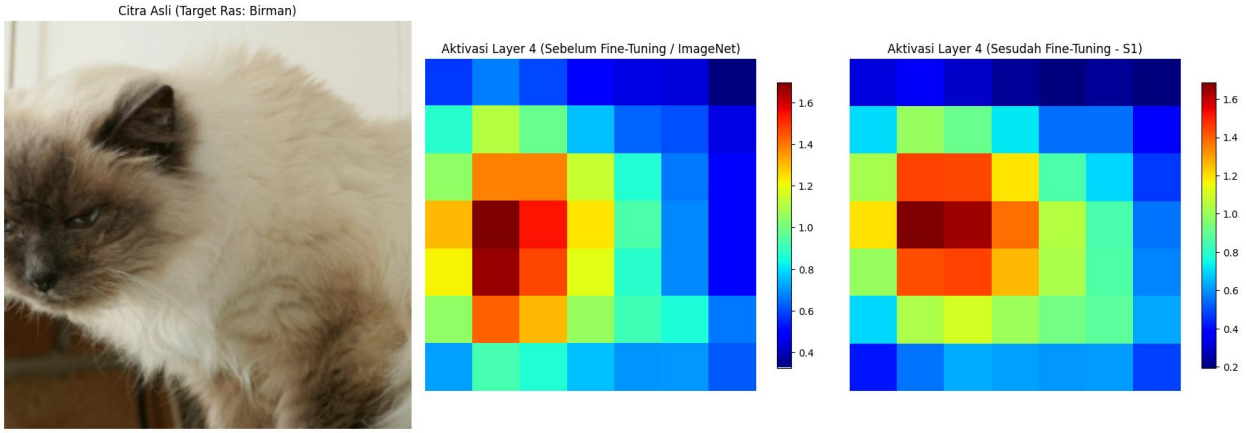
C3.



Jika dilihat dari hasil kesalahan tetap terjadi pada ras yang sama yang berarti model dapat membedakan 2 jenis hewan. Kesalahan prediksi bisa terjadi karena kemiripan ras dari berbagai factor seperti pola warna ukuran telinga dll. Apabila kita melihat American Pit Bull Terier dan American Bulldog sebagai contoh, mereka memiliki bentuk muka yang mirip.

C4. Dari eksperimen yang saya lakukan, berdasarkan 994 data yang dipakai fine tune masih memiliki performa paling baik dan possible untuk dilakukan. Dengan resource terbatas (dalam hal ini menggunakan google collab) waktu untuk mengolah data dengan 11 juta parameter tidak terlalu jauh berbeda dengan feature extract. Tetapi fine tunee memiliki kecenderungan ovefit yang mungkin bisa diperbaiki dengan approach lain.

C5.



Melihat dari pergeseran heatmap setelah fine tuning, model bergeser tidak hanya fokus melihat kepada hidung dan mata tetapi juga mulai fokus kepada bulu dan telinga dari kucing

Penggunaan AI :

- Pembuatan kode (google collab, gemini flash)
- Research konseptual (chat gpt)